Lecture 9
Coding and Non-Coding Genes
HIDDEN MARKOV MODELS I

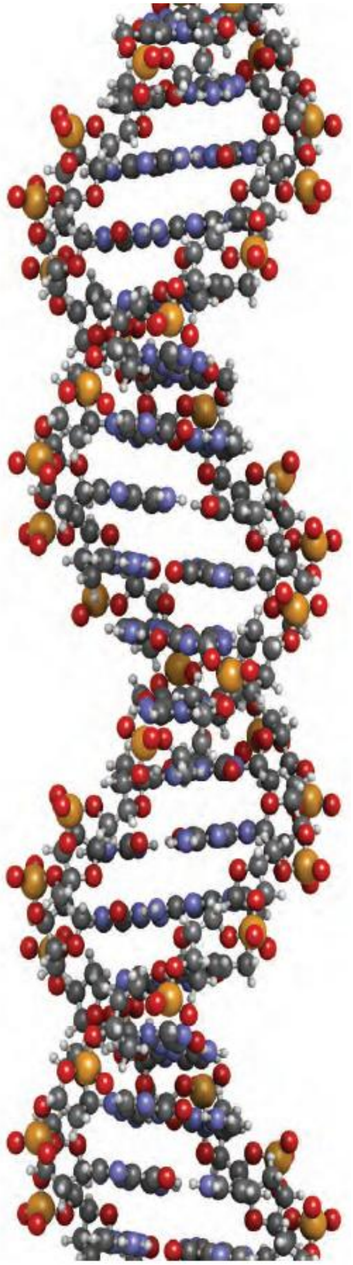

1. HIDDEN MARKOV MODELS - HMM

Úvod do Skrytých Markovových modelov (HMM)

- **Definícia:** HMM sú fundamentálny nástroj strojového učenia pre analýzu sekvencií.

- **Využitie v Bioinformatike:**
  - Skúmanie štruktúry DNA a polypeptidov.
  - Identifikácia funkčných elementov (gény, exóny, intróny).
  - Detekcia štatisticky anomálnych oblastí (CpG ostrovy, promótory).

- **Cieľ: Odhaliť „skrytú“ štruktúru, ktorá nie je priamo viditeľná z primárnej sekvencie.**

Skryté Markovove modely (HMM) sú základným nástrojom strojového učenia, ktorý sa široko využíva v výpočtovej biológii. Pomocou HMM môžeme skúmať základnú štruktúru sekvencií DNA alebo polypeptidov a detegovať oblasti osobitného záujmu. Môžeme napríklad identifikovať konzervované podsekvencie alebo odhaliť oblasti so štatisticky odlišným rozložením nukleotidov alebo aminokyselín, ako sú promótorové oblasti alebo CpG ostrovy. Tento pravdepodobnostný model možno použiť na objasnenie vlastností a štrukturálnych komponentov sekvencií, čo nám umožňuje lokalizovať gény a iné funkčné prvky.

Toto je prvá z troch prednášok o HMM. V tejto prednáške definujeme Markovove reťazce a HMM a poskytneme sériu motivujúcich príkladov. V druhej polovici tejto prednášky budeme diskutovať o skórovaní a dekódovaní HMM. Naučíme sa, ako vypočítať pravdepodobnosť konkrétnej kombinácie pozorovaní a stavov. Predstavíme Forward algoritmus na výpočet pravdepodobnosti danej sekvencie pozorovaní naprieč všetkými možnými sekvenciami stavov.

Ďalej budeme diskutovať o Viterbiho algoritme, ktorý poskytuje metódu na určenie najpravdepodobnejšej cesty stavov, ktorá viedla k daným pozorovaniam.
Potom budeme pokračovať v našej diskusii o dekódovaní skúmaním posteriórneho dekódovania, ktoré nám umožňuje vypočítať najpravdepodobnejší stav v každom bode sekvencie. Potom preskúmame, ako sa naučiť Skrytý Markovov model - HMM. Vysvetlíme učenie s učiteľom aj bez učiteľa a vysvetlíme, ako možno každé z nich použiť na naučenie parametrov modelu. Pri učení s učiteľom máme k dispozícii trénovacie dáta, ktoré označujú sekvencie konkrétnymi modelmi. Pri učení bez učiteľa nemáme štítky, takže sa musíme snažiť rozdeliť dáta do diskrétnych kategórií na základe objavených pravdepodobnostných podobností. V našej diskusii o učení bez učiteľa predstavíme široko aplikovateľný a zovšeobecniteľný algoritmus Expectation Maximization (EM).

1. HIDDEN MARKOV MODELS - HMM

Motivácia: Máme novú sekvenciu DNA, čo teraz?

Zarovnať ju:

- k veciam, o ktorých vieme (vyhľadávanie v databáze).
- k neznámym veciam (skladanie/zhlukovanie). Napríklad poskladať celý genóm spájaním a skladaním špecifických génov.

Vizualizovať ju: „Pravidlo genomiky č. 1“: Pozrite sa na svoje dáta!

- Hľadajte neštandardné zloženie nukleotidov (napr. promótorové oblasti, CpG ostrovy).
- Hľadajte frekvencie k-mérov, ktoré sú spojené s oblasťami kódujúcimi proteíny, opakujúcimi sa dátami, vysokým obsahom GC atď.
- Hľadajte motívy, evolučné signatúry.
- Preložte ju a hľadajte otvorené čítacie rámce, stop kodóny atď.
- Hľadajte vzorce, potom vyviňte nástroje strojového učenia na určenie rozumných pravdepodobnostných modelov. Napríklad pohľadom na množstvo štvoríc sa rozhodneme ich farebne odlíšiť, aby sme videli, kde sa vyskytujú najčastejšie.

- **Modelovať ju:**
  - Vytvorte hypotézy.
  - Zostavte generatívny model na opísanie hypotéz. Napríklad skúmanie toho, čo robí človeka „človekom“ (oči, nos, ústa) a zostavenie modelu na vygenerovanie nového človeka na základe čŕt určených ako ľudské charakteristiky.
  - Použite tento model na nájdenie sekvencií podobného typu.

1. HIDDEN MARKOV MODELS - HMM

Koncepcia Generatívnych modelov

Čo je to generatívny model?

- Model, ktorý dokáže „vytvoriť“ nové dáta s vlastnosťami originálu.
- Analógia: Ak vieme, čo robí človeka „človekom“ (oči, nos), môžeme podľa modelu vygenerovať novú tvár.

Aplikácia na genóm:

- Cieľom je anotácia: Rozlíšiť exóny, intróny, promótory.
- Modelovanie malých aspektov genómu (keďže celý genóm naraz je príliš komplexný).

Schopnosti pravdepodobnostného rámca

Dobré modely (ako HMM) nám umožňujú tri kľúčové činnosti:

- **Emisia:** Generovanie nových sekvencií, ktoré „vyzerajú“ ako cieľový biologický objekt.
- **Rozpoznávanie:** Určenie, ktorý skrytý biologický stav (napr. „exón“) najpravdepodobnejšie vyprodukoval pozorovanú nukleotidovú sekvenciu.
- **Učenie:**

  S učiteľom: Trénovanie na ručne anotovaných dátach (gold standard).

  Bez učiteľa: Automatické hľadanie kategórií v neoznačených dátach na základe pravdepodobnostnej podobnosti.

Prečo práve pravdepodobnosť? (Vysvetliteľnosť)

Bioinformatika uprednostňuje pravdepodobnostné modely (HMM) pred binárnymi z týchto dôvodov:

- **Odolnosť voči šumu:** Biologické dáta sú prirodzene variabilné a zašumené.
- **Aktualizácia znalostí:** Možnosť integrovať predchádzajúce biologické vedomosti do parametrov modelu.
- **Stupne presvedčenia:** Modely nedávajú len odpoveď ÁNO/NIE.
  - Namiesto: „Toto je promótor.“
  - Hovoria: „Je tu **75 % šanca**, že toto je promótor.“
- **Matematický aparát:** Pravdepodobnosť poskytuje presný kalkul pre prácu s neistotou.

1. Markovove reťazce a HMM

Motivačný príklad:

Predpoveď počasia

Predpovedanie počasia bolo vždy náročné, najmä ak by sme chceli predpovedať počasie mnoho dní, týždňov alebo mesiacov vopred. Ak však potrebujeme predpovedať počasie len na nasledujúci deň, môžeme dosiahnuť slušnú presnosť pomocou jednoduchých modelov, ako sú Markovove reťazce (MC – Markoc Chain) a Skryté Markovove modely (HMM – Hidden Markov Models).

Vľavo je model Markovovho reťazca - MC, ktorý pozostáva zo štyroch typov počasia (Slnko, Dážď, Oblaky a Sneh), ktoré môžu priamo prechádzať jeden do druhého. V tomto prípade platí: „to, čo vidíte, je to, čo dostanete“ v tom zmysle, že nasledujúci stav závisí len od aktuálneho stavu; neexistuje žiadna pamäť na akýkoľvek predchádzajúci stav.
Vpravo je HMM, v ktorom sú typy počasia modelované ako emisie (alebo výsledky) neznámych alebo „skrytých“ ročných období (Leto, Jeseň, Zima a Jar). Kľúčovým poznatkom za HMM je, že skryté stavy modelu (napr. ročné obdobia) určujú pravdepodobnosti emisií, zatiaľ čo prechody medzi skrytými stavmi sa riadia Markovovým reťazcom.

MC

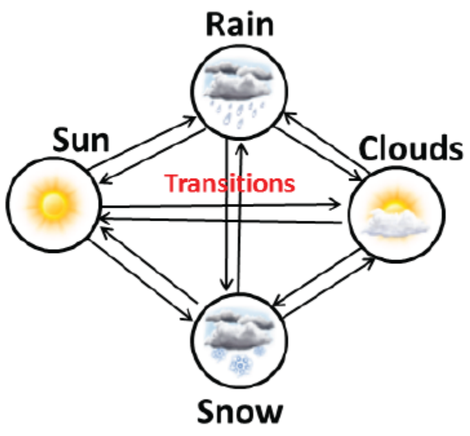

HMM

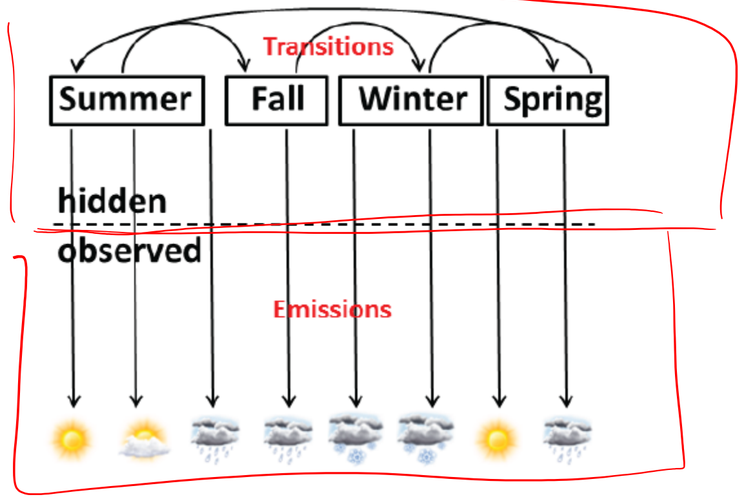

Historické okienko

História Markovových reťazcov je fascinujúcim príkladom toho, ako môže čistá vedecká rivalita a snaha vyvrátiť nábožensko-filozofické tvrdenie viesť k vzniku jedného z najdôležitejších nástrojov modernej vedy a bioinformatiky.

Kto to bol?

Andrej Andrejevič Markov (1856–1922) bol ruský matematik a profesor na univerzite v Petrohrade. Bol známy svojou tvrdohlavosťou, pedantnosťou a záľubou v intelektuálnych súbojoch. V Rusku ho prezývali „Zlatý Andrej“ nielen pre jeho brilantnú myseľ, ale aj pre jeho nekompromisnú povahu.

Ako to celé vzniklo: Súboj o slobodnú vôľu

Na začiatku 20. storočia prebiehal v Rusku ostrý spor medzi petrohradskou matematickou školou a teológmi.

- **Argument teológov:** Mnohí učenci vtedy tvrdili, že štatistika a pravdepodobnosť dokazujú existenciu božskej prozreteľnosti a slobodnej vôle. Operovali s tzv. **Zákonom veľkých čísel**, ktorý hovoril, že ak sú javy nezávislé (ako hody kockou), výsledok sa ustáli na priemere. Tvrdili, že ak by javy boli závislé (jeden by ovplyvňoval druhý), nastal by chaos. Z toho vyvodzovali, že svet musí byť súborom nezávislých udalostí riadených vyššou mocou.

- **Markovova reakcia:** Markov, ktorý bol zarytým ateistom, chcel dokázať, že **závislosť medzi udalosťami nemusí viesť k chaosu** a že matematické zákony fungujú aj vtedy, keď nasledujúci krok priamo vyplýva z toho predchádzajúceho.

Historické okienko

Prvý "počítačový" lingvista

Aby Markov dokázal svoju teóriu, potreboval dáta. Keďže v roku 1913 nemal počítače, rozhodol sa pre manuálnu analýzu literatúry.

1. Vzal si Puškinov slávny román vo veršoch **„Eugen Onegin“**.
2. Prešiel prvých **20 000 písmen** textu.
3. Ručne si značil, kedy po samohláske nasleduje spoluhláska a naopak.
4. Zistil, že pravdepodobnosť výskytu ďalšieho písmena silne závisí od typu písmena, ktoré mu predchádzalo.

Týmto vytvoril prvý model, kde **budúci stav (typ písmena) bol určený aktuálnym stavom**. Dokázal, že aj v takomto systéme platí štatistická rovnováha. Tento „reťazec“ závislostí dostal neskôr jeho meno.

Prečo je to dôležité dnes?

To, čo Markov začal ako analýzu Puškina, dnes poháňa svet:

- **Google PageRank:** Pôvodný algoritmus Googlu vnímal web ako Markovov reťazec – šanca, že kliknete na ďalšiu linku, závisí od stránky, na ktorej ste teraz.
- **Prediktívny text:** Keď vám telefón navrhuje ďalšie slovo v správe, používa v podstate Markovov model.
- **Bioinformatika (HMM):** V bioinformatike používame jeho princíp na modelovanie DNA. Predpokladáme, že typ nukleotidu na pozícii $i+1$ je ovplyvnený tým, čo bolo na pozícii i. Markov by bol pravdepodobne v šoku, keby vedel, že jeho snaha vyvrátiť teologické argumenty pomocou Puškinových básní sa o 100 rokov neskôr stane základom pre čítanie ľudského genómu.

Formalizácia Markovovho reťazca a HMM

Aby sme plne porozumeli Skrytým Markovovým modelom - HMM, musíme definovať kľúčové parametre, ako je znázornené na obrázku.

to čo je skryté →

to čo vidíme →

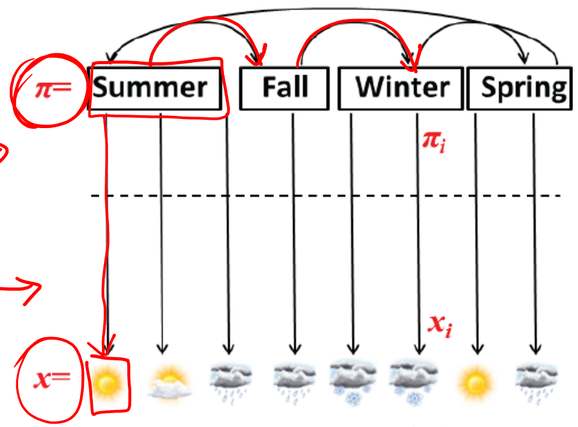

Transitions: $a_{kl}=P(\pi_i=l|\pi_{i-1}=k)$
Transition probability from state k to state l

Emissions: $e_k(x_i)=P(x_i|p_i=k)$
Emission probability of symbol x_i from state k

$P(A|B) = \frac{P(A,B)}{P(B)} =$ (združená prav)

$P(A|B)\cdot P(B) = P(A,B) =$

$P(B|A)\cdot P(A)$

Vektor x predstavuje sekvenciu pozorovaní (emisií). → to čo vidíme

Vektor π predstavuje skrytú cestu, čo je sekvencia skrytých stavov. → to čo nevidíme, ale ovplyvňuje situáciu

Každý záznam a_{kl} matice prechodov A označuje pravdepodobnosť prechodu zo stavu k do stavu l.

Každý záznam $e_k(x_i)$ emisného vektora označuje pravdepodobnosť pozorovania x_i zo stavu k.

Napokon, s týmito parametrami a Bayesovým pravidlom môžeme použiť známe

$p(x_i \mid \pi_i = k)$ na odhad neznámej pravdepodobnosti $p(\pi_i = k \mid x_i)$.

je leto → je leto | vidím slniečko

$P(A|B)$ — evidence; jav; za predpokladu že nastane jav B

$P(A)$

Markovove reťazce – Markov Chain - MC

- Markovov reťazec je definovaný konečnou množinou stavov a pravdepodobnosťami prechodu medzi týmito stavmi.
- V každom časovom kroku sa Markovov reťazec nachádza v konkrétnom stave a podstupuje prechod do iného stavu.
- Pravdepodobnosť prechodu do každého iného stavu závisí len od aktuálneho stavu, nezávisle od toho, ako bol aktuálny stav dosiahnutý.

Formálnejšie,

Markovov reťazec je trojica (Q, p, A), ktorá pozostáva z:

- Množiny stavov Q. = {Sun, Rain, Cloud, Snow}
- Matice prechodov A, ktorej prvky A_{ij} zodpovedajú pravdepodobnosti prechodu zo stavu i do stavu j.
- Vektora p pravdepodobností počiatočných stavov.

$$\begin{array}{c|cccc} & S & R & C & Sn \\ \hline S & 0.7 & 0.2 & 0.3 & 0.1 \\ R & & & & \\ C & & & & \\ Sn & & & & \end{array}$$

$$\text{DNES} = \begin{array}{c} \\ \begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \end{bmatrix} \end{array} \begin{array}{c} S \\ R \\ C \\ Sn \end{array}$$

p.o A_{ij}

Kľúčovou vlastnosťou Markovových reťazcov je, že sú bezpamäťové, t. j. každý stav závisí len od predchádzajúceho stavu.

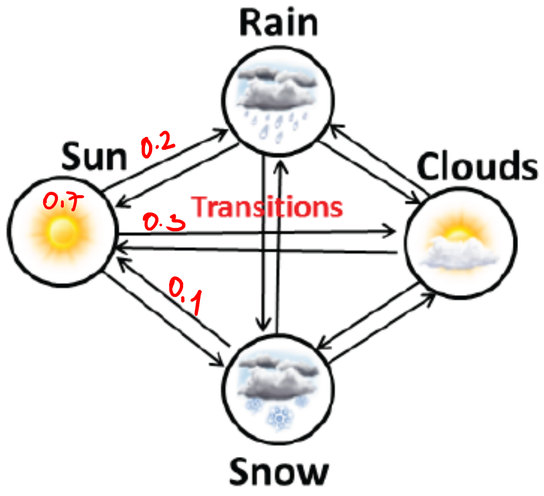

1. HIDDEN MARKOV MODELS - HMM

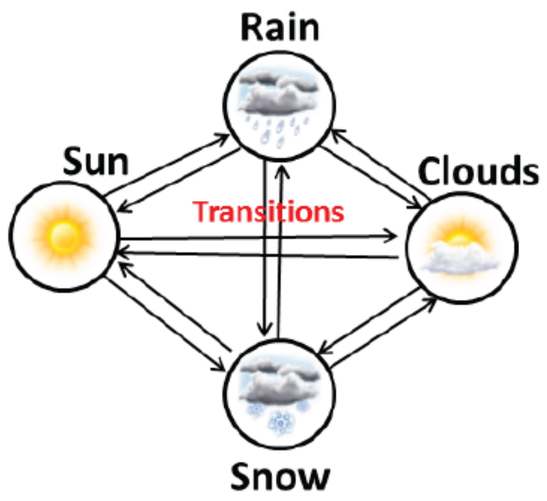

Takže môžeme okamžite definovať pravdepodobnosť nasledujúceho stavu vzhľadom na aktuálny stav:

zajtra dnes včera keď bol svet stvorený

$$P(x_i \mid x_{i-1}, \ldots, x_1) = P(x_i \mid x_{i-1})$$

čo bolo zajtra dnes

Týmto spôsobom možno pravdepodobnosť celej sekvencie rozložiť nasledovne:

zajtra dnes dnes včera

$$P(x) = P(x_L, x_{L-1}, \ldots, x_1) = P(x_L \mid x_{L-1}) P(x_{L-1} \mid x_{L-2}) \ldots P(x_2 \mid x_1) P(x_1)$$

združení

$P(x_L)$ sa dá vypočítať aj z pravdepodobností prechodu.

Ak vynásobíme pravdepodobnosti počiatočného stavu v čase $t = 0$ maticou prechodov A, dostaneme pravdepodobnosti stavov v čase $t = 1$. Preto ich vynásobenie maticou prechodov umocnenou na príslušnú mocninu A^L poskytuje pravdepodobnosti stavov v čase $t = L$.

$$P(x_i \mid x_{i-1}, x_{i-2}, \ldots x_1)$$

združení

$$= \frac{P(x_i, x_{i-1}, x_{i-2}, \ldots x_1)}{P(x_{i-1}, x_{i-2}, \ldots x_1)}$$

Príklad pre Markovov reťazec (MC): „Akciový trh“

Markovov reťazec používame vtedy, keď **stavy priamo vidíme**
a predpokladáme, že zajtrajšok závisí len od dneška.

Model: Máme tri stavy trhu:

1. **Býčí trh (Bull):** Ceny rastú.
2. **Medvedí trh (Bear):** Ceny klesajú.
3. **Stagnácia (Stagnant):** Ceny sa nemenia.

Matica prechodov (*A*):

Predpokladajme, že ak je dnes trh „Býčí“, je 90 % šanca, že taký zostane aj zajtra, 7 % šanca, že začne stagnovať a len 3 % šanca, že padne do „Medvedieho“ trendu.

Prečo je to MC?

- **Viditeľnosť:** Stačí sa pozrieť na burzu a vieme, v akom stave sme.
- **Bezpamäťovosť:** Investor v tomto modeli predpokladá, že pre predpoveď na zajtra nepotrebuje vedieť, ako sa trh správal pred mesiacom. Stačí mu dnešná hodnota.

Príklad pre HMM: „Detektív a hladina cukru“

HMM používame vtedy, keď to, čo nás zaujíma (stav), **nemôžeme vidieť**, ale vidíme jeho **prejavy (emisie)**.

Scenár: Detektív sleduje podozrivého. Nemôže vidieť, čo podozrivý jedol (skrytý stav), ale vidí, ako sa podozrivý správa – či je hyperaktívny, unavený alebo normálny (emisie). → vidím

Skryté stavy (*Q*):

1. **Stav „Cukrový šok“:** Podozrivý práve zjedol kilovú tortu.
2. **Stav „Hladovanie“:** Podozrivý nič nejedol 12 hodín.

Emisie (*V*):

- Behanie dokola (vysoká energia).
- Zívanie (nízka energia).
- Sedenie (normálna energia).

Matica emisií (*E*):

- V stave **„Cukrový šok“** je 80 % pravdepodobnosť emisie „Behanie dokola“.
- V stave **„Hladovanie“** je 70 % pravdepodobnosť emisie „Zívanie“.

Prečo je to HMM?

- Detektív vidí „Zívanie“. Znamená to stopercentne, že podozrivý hladuje?
  Nie. Možno je len unavený v stave „Cukrový šok“ (20 % šanca).
- Úlohou HMM je vypočítať, ktorá sekvencia jedenia (skrytá cesta) najlepšie vysvetľuje pozorovanú sekvenciu správania.

1. HIDDEN MARKOV MODELS - HMM

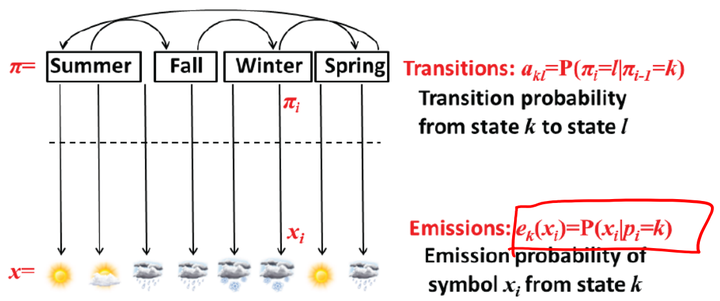

Skryté Markovove modely

Skryté Markovove modely sa používajú na reprezentáciu problémového priestoru, v ktorom pozorovania vznikajú ako výsledok stavov systému, ktoré nie sme schopní priamo pozorovať. Tieto pozorovania alebo emisie vyplývajú zo skrytých stavov na základe súboru pravdepodobností spojených s týmito stavmi. Tieto pravdepodobnosti sú známe ako emisné pravdepodobnosti.

Formálne je Skrytý Markovov model 5-tica (Q, A, p, V, E), ktorá pozostáva z nasledujúcich parametrov:

- Séria stavov, Q. = (S, R, C, S, W)
- Matica prechodov, A. → rovnaké
- Vektor pravdepodobností počiatočných stavov, p. → rovnaké
- Množina symbolov pozorovaní, V, napríklad $\{A, T, C, G\}$ alebo množina aminokyselín či slov v anglickom slovníku.
- Matica emisných pravdepodobností, E: Pre každé s, t v Q je emisná pravdepodobnosť:

$$e_{sk} = P(v_k \text{ v èase } t \mid q_t = s)$$

Kľúčová vlastnosť bezpamäťovosti je zdedená z Markovových modelov, takže emisie a prechody závisia len od aktuálneho stavu a nie od minulej histórie.

1. HIDDEN MARKOV MODELS - HMM

Parameter	Markovov reťazec (MC)	Skrytý Markovov model (HMM)
Príklad	Indexy na burze (Bull/Bear)	Detektív (Strava vs. Správanie)
Čo pozorujeme?	Priamo stavy systému.	Len emisie (prejavy) stavov.
Otázka modelu	Aká je šanca, že zajtra bude trh rásť?	Aká je šanca, že podozrivý hladuje, keď zíva?
Bioinformatika	Sekvencia DNA (nukleotid po nukleotide).	Je tento úsek DNA exón alebo intrón?

V bioinformatike je HMM silnejší, pretože nám umožňuje
interpretovať „šum“ (sekvenciu písmen A, C, G, T)
ako zmysluplné biologické stavy, ktoré sú inak neviditeľné.

Nepoctivé kasíno

Scenár

Predstavte si nasledujúci scenár: Vstúpite do kasína, ktoré ponúka hru s hádzaním kockou. Stavíte 1$ a vy aj krupiér hodíte kockou. Ak hodíte vyššie číslo, vyhrávate 2$. Táto zdanlivo jednoduchá hra má však háčik. Ste si vedomí toho, že kasíno má dva typy kociek:

1. **Férová kocka:** $P(1) = P(2) = P(3) = P(4) = P(5) = P(6) = 1/6$
2. **Falošná (zaťažená) kocka:** $P(1) = P(2) = P(3) = P(4) = P(5) = 1/10$ a $P(6) = 1/2$

Krupiér môže medzi týmito dvoma kockami kedykoľvek prepínať bez toho, aby ste o tom vedeli; jediné informácie, ktoré máte, sú hody, ktoré pozorujete. V priemere krupiér vymení kocky každých 20 ťahov. Stav kocky v kasíne môžeme reprezentovať jednoduchým Markovovým modelom:

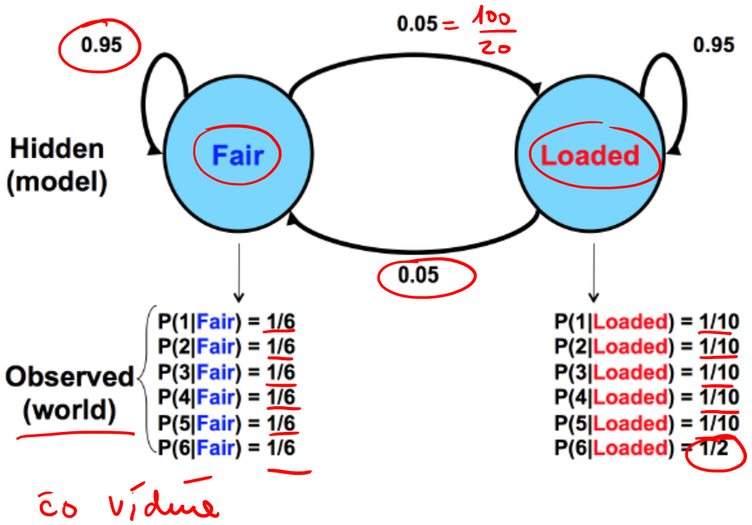

Model zobrazuje dva možné stavy, ich emisie a pravdepodobnosti prechodu a emisie.

Fér
Falošná

pokiaľ 1
2
3
4
5
6

vymení kocku
nevym - "-

Klasický príklad HMM – Nepoctivé kasíno

- Problém: Pozorujeme sériu hodov kockou. Nevieme, či krupiér používa férovú (Fair) alebo falošnú (Loaded) kocku.
- Parametre modelu:
  - Férová kocka (F): Každé číslo (1-6) má šancu $1/6 \approx 16{,}6\%$.
  - Falošná kocka (L): Čísla 1-5 majú šancu $1/10 = 10\%$, číslo 6 má šancu $1/2 = 50\%$.
- Prechody medzi stavmi:
  - Krupiér mení kocku priemerne každých 20 hodov.
  - Pravdepodobnosť zostať pri rovnakej kocke: $\boxed{P(F \mid F)} = 0{,}95$; $P(L \mid L) = 0{,}95$. 19 hodov z 20
  - Pravdepodobnosť zmeny: $P(L \mid F) = 0{,}05$; $P(F \mid L) = 0{,}05$.

každý 20ty hod mení

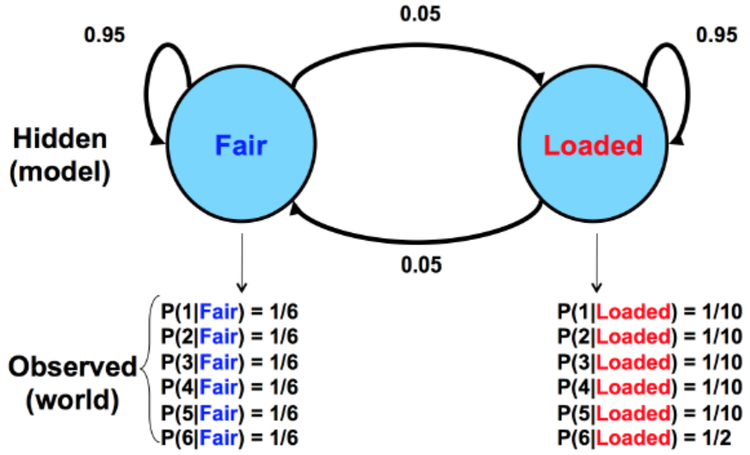

Biologická analógia: nepoctivý genóm

Obrázok uvádza podobný model pre biologickú situáciu, v ktorej má sekvencia DNA dva potenciálne zdroje:

- injekciu vírusom alebo
- normálnu produkciu samotným organizmom.

Tento model predpokladá, že **vírusové insercie budú mať vyššiu prevalenciu CpG**, čo vedie k vyšším pravdepodobnostiam emisie C a G.

Okrem toho sa a priori predpokladá, že je veľmi pravdepodobné, že sekvencia pochádza z vlastného genómu a že prechody na vírusovú DNA sú nepravdepodobné, čo vedie k pravdepodobnostiam prechodu zobrazeným v modeli.

Ak vezmeme tento model ako hypotézu, pozorovali by sme frekvencie C a G, ktoré by nám poskytli indície o zdroji predmetnej sekvencie.

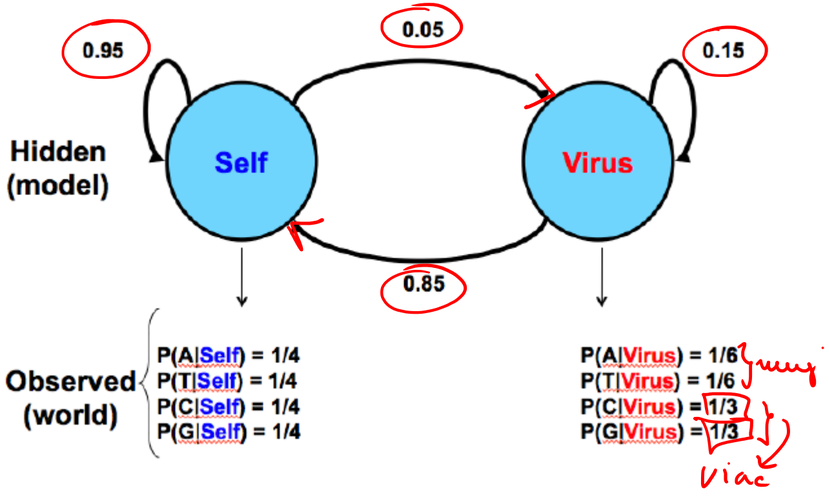

Biologická paralela – „Nepoctivý genóm“

- HMM nie je len o kasíne: Rovnakú matematiku aplikujeme na analýzu DNA.
- Scenár: Sekvencia DNA môže pochádzať z dvoch zdrojov (skryté stavy):
    1. Vlastný genóm: Normálna produkcia organizmu.
    2. Vírusový inzerát: DNA vložená vírusom.
- Emisie (Pozorovania):
    - Vírusová DNA má často iné zloženie (napr. vyšší výskyt dvojíc CpG → viac C a G).
    - Ak v sekvencii vidíme náhly nárast C a G, HMM nám pomôže určiť, či ide o náhodu alebo o vírusový úsek.
- Vysvetliteľnosť: HMM tu funguje ako detektor „cudzieho“ elementu v domácom genóme na základe štatistických anomálií.

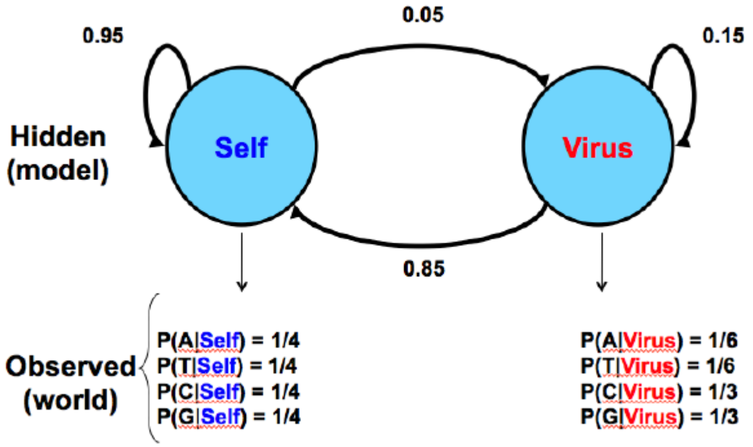

Spustenie modelu

Povedzme, že sme v kasíne a pozorujeme sekvenciu hodov uvedenú na obrázku

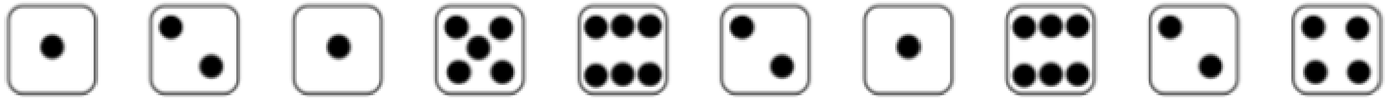

Radi by sme vedeli, či je pravdepodobnejšie, že kasíno používa férovú alebo falošnú kocku.

Aby sme lepšie pochopili správanie základného HMM, zvážime dve možné sekvencie stavov:

- jednu, v ktorej krupiér vždy používa férovú kocku, a
- druhú, v ktorej krupiér vždy používa falošnú kocku.

Pre každý prípad chceme vypočítať združenú pravdepodobnosť pozorovaného výsledku pri danej sekvencii skrytých stavov.

2. Aplikácie HMM: Od kasína k biológii

V prípade, že krupiér používa iba férovú kocku, pravdepodobnosti prechodu a emisie sú znázornené na obrázku

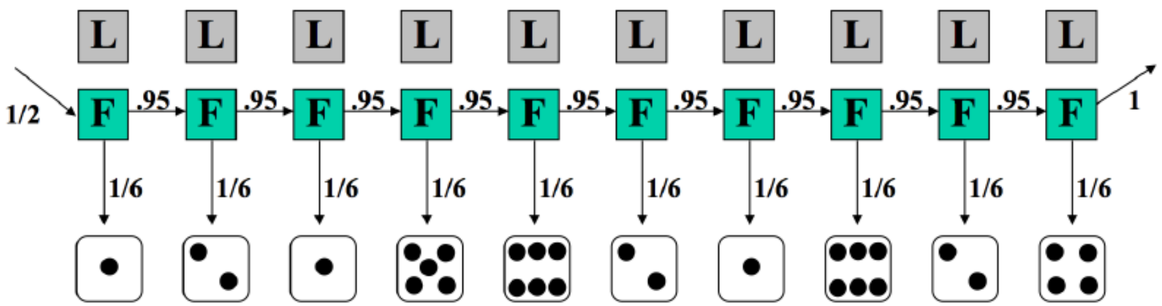

Predpokladáme $\pi = \{F, F, F, F, F, F, F, F, F, F\}$ a pozorujeme $x = \{1, 2, 1, 5, 6, 2, 1, 6, 2, 4\}$.

Pravdepodobnosť, že táto sekvencia stavov vyprodukuje pozorované emisie, je súčinom troch členov:

- $1/2$ (pravdepodobnosť začatia s férovou kockou);
- $(1/6)^{10}$ (pravdepodobnosť vyprodukovania sekvencie férovou kockou); a
- $(0,95)^9$ (pravdepodobnosť, že vždy budeme pokračovať v používaní férovej kocky).

Preto:

$$P(x, \pi) = P(x \mid \pi)P(\pi) = \frac{1}{2} \times P(1 \mid F) \times P(F \mid F) \times P(2 \mid F) \ldots = \frac{1}{2} \times (1/6)^{10} \times (0,95)^9 = 5,2 \times 10^{-9}$$

Keďže je táto pravdepodobnosť taká malá, mohlo by sa zdať, že ide o extrémne nepravdepodobný prípad. V skutočnosti je pravdepodobnosť nízka jednoducho preto, že existuje veľké množstvo možných sekvencií, takže žiadny výsledok nie je a priori pravdepodobný.

2. Aplikácie HMM: Od kasína k biológii

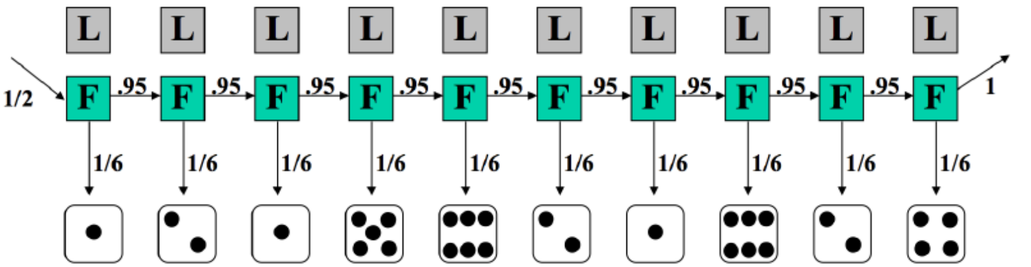

Aby sme pochopili vzťah z obrázku, musíme si uvedomiť, že počítame **združenú pravdepodobnosť** $P(x,\pi)$. To znamená, že sa pýtame: „Aká je šanca, že sa stane táto konkrétna séria hodov (x) **A ZÁROVEŇ** že krupiér použil túto konkrétnu sériu kociek (π)?“

Odvodili sme vzorec:

$$P(x,\pi) = \frac{1}{2} \times \left(\frac{1}{6}\right)^{10} \times (0,95)^{9}$$

Poďme si tento mechanizmus odvodiť postupne od najjednoduchšieho prípadu, aby sme videli, prečo to tak je.

Ak hodíte mincou, v 50 % prípadov (polovica vesmírov) padne Hlava. Len v týchto prípadoch nás zaujíma, čo padne na kocke. Na kocke padne šestka len v 1 zo 6 prípadov. Takže hľadáme **jednu šestinu z jednej polovice**.

Matematicky:

$$P(\text{Hlava} \cap \text{šestka}) = \frac{1}{2} \times \frac{1}{6} = \frac{1}{12}$$

Ak by ste si vypísali všetky možnosti (Hlava-1, Hlava-2... Orol-1, Orol-2...), zistíte, že ich je celkovo 12 a len jedna z nich je Hlava-Šestka. Násobenie je teda skratka, ako sa k tomuto číslu dopracovať bez vypisovania všetkých možností.

2. Aplikácie HMM: Od kasína k biológii

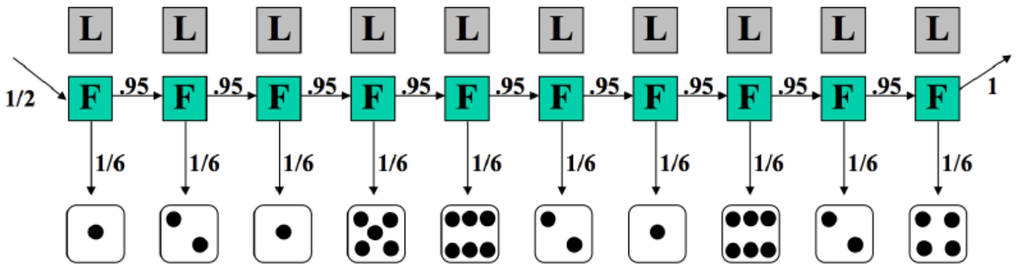

Súvis s HMM a nepoctivým kasínom

V HMM, keď počítame pravdepodobnosť cesty π a emisií x, robíme presne toto isté, len mnohokrát za sebou.

Predstavte si to ako dlhý **reťazec podmienok**, ktoré musia nastať naraz:

1. **Musíme** začať s férovou kockou ($1/2$).
2. **A ZÁROVEŇ** musí padnúť číslo 1 ($1/6$).
3. **A ZÁROVEŇ** krupiér nesmie vymeniť kocku ($0{,}95$).
4. **A ZÁROVEŇ** v ďalšom kole musí padnúť číslo 2 ($1/6$).

Každé „A ZÁROVEŇ“ v pravdepodobnosti znamená **krát**. Preto vzorec vyzerá ako jeden dlhý súčin:

$$P(x,\pi) = \text{štart} \times \text{Emisia}_1 \times \text{Prechod}_{1\to 2} \times \text{Emisia}_2 \times \ldots$$

Dôležitá poznámka: Nezávislosť

Násobiť môžeme takto jednoducho len vtedy, ak sú javy nezávislé (minca neovplyvní kocku). V HMM sú stavy závislé na predchádzajúcom stave (Markovova vlastnosť), ale práve preto používame **podmienenú pravdepodobnosť** (napr. $P(\text{zostane F} \mid \text{bol predtým F})$), ktorú stále môžeme násobiť do celkového reťazca.

2. Aplikácie HMM: Od kasína k biológii

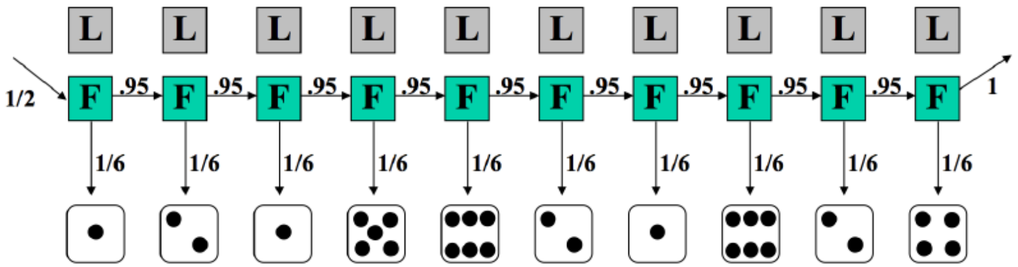

Prípad 1: 2 hody kockou (Séria: 1, 2 | Kocky: F, F)

Predstavme si, že hodíme dvakrát. Pozorujeme emisie $x = \{1, 2\}$ a predpokladáme skrytú cestu $\pi = \{F, F\}$.

1. **Štart ($t = 1$):** Musíme začať v stave „Férová kocka". Šanca na štart je $1/2$.
2. **Prvá emisia ($t = 1$):** V stave F musí padnúť číslo 1. Pravdepodobnosť je $P(1|F) = 1/6$.
3. **Prechod ($t = 1 \to 2$):** Musíme zostať v stave F aj pre druhý hod. Pravdepodobnosť prechodu $P(F|F) = 0,95$.
4. **Druhá emisia ($t = 2$):** V stave F musí teraz padnúť číslo 2. Pravdepodobnosť je $P(2|F) = 1/6$.

Výpočet pre 2 hody:

$$P(x,\pi) = \underbrace{\frac{1}{2}}_{\text{štart}} \times \underbrace{\frac{1}{6}}_{\text{1.hod}} \times \underbrace{0,95}_{\text{prechod}} \times \underbrace{\frac{1}{6}}_{\text{2.hod}}$$

Zjednodušene: $\frac{1}{2} \times \left(\frac{1}{6}\right)^2 \times (0,95)^1$

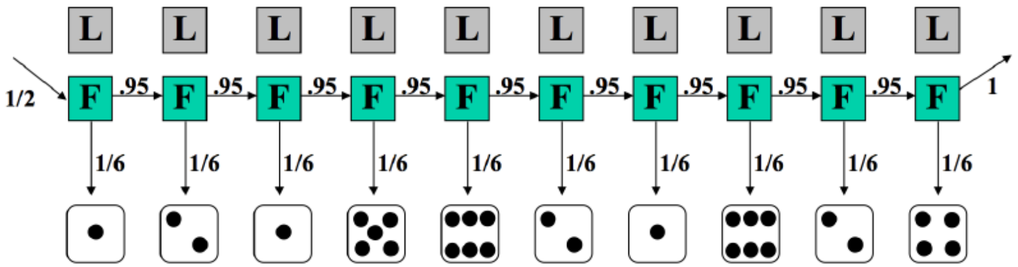

Prípad 2: 3 hody kockou (Séria: 1, 2, 1 | Kocky: F, F, F)

Pridajme tretí hod. Opäť predpokladáme, že krupiér stále drží férovú kocku.

1. Máme základ z predchádzajúcich dvoch hodov.
2. **Prechod ($t = 2 \rightarrow 3$):** Opäť musíme zostať v stave F. Šanca je $P(F \mid F) = 0{,}95$.
3. **Tretia emisia ($t = 3$):** Musí padnúť číslo 1. Šanca je $P(1 \mid F) = 1/6$.

Výpočet pre 3 hody:

$$P(x,\pi) = \frac{1}{2} \times \frac{1}{6} \times 0{,}95 \times \frac{1}{6} \times \mathbf{0{,}95} \times \frac{\mathbf{1}}{\mathbf{6}}$$

Zjednodušene: $\frac{1}{2} \times \left(\frac{1}{6}\right)^3 \times (0{,}95)^2$

Zovšeobecnenie pre L hodov

Ak si všimnete vzorec, vzniká tam jasná zákonitosť pre dĺžku sekvencie L:

- **Štartovacia pravdepodobnosť:** Vyskytuje sa vždy **1-krát** na začiatku.
- **Emisná pravdepodobnosť (**$1/6$**):** Vyskytuje sa presne L**-krát** (raz pre každý hod).
- Pravdepodobnosť prechodu (***0,95***): Vyskytuje sa $(L-1)$ -krát. Prečo? Pretože ak máme napríklad 3 hody, robíme len 2 prechody (medzi 1. a 2. hodom a medzi 2. a 3. hodom).

Prečo je výpočet z obrázku správny?

V príklade máme **10 hodov** ($L=10$) a predpokladáme, že všetky boli vykonané férovou kockou ($\pi=\{F,F,\ldots,F\}$).

Dosadíme do nášho zovšeobecneného vzorca:

- Počet emisií: $10 \Rightarrow (1/6)^{10}$
- Počet prechodov: $10-1=9 \Rightarrow (0,95)^{9}$
- Štart: $1/2$

Výsledok:

$$P(x,\pi)=\frac{1}{2}\times\left(\frac{1}{6}\right)^{10}\times(0,95)^{9}$$

Tento výpočet presne sedí. Ukazuje nám šancu, že systém prešiel cestou „vždy férový“ a vygeneroval práve túto sekvenciu hodov. Ak by sme chceli vypočítať pravdepodobnosť pre **falošnú kocku**, zmenili by sa len emisné hodnoty (niektoré by boli $1/10$ a tie, kde padla 6-ka, by boli $1/2$), ale logika násobenia prechodov a emisií by zostala identická.

2. Aplikácie HMM: Od kasína k biológii

Poďme si teraz rozobrať **situáciu**, ktorý analyzuje opačný extrém: hypotézu, že krupiér **celý čas podvádzal** a používal výhradne falošnú (zaťaženú) kocku.

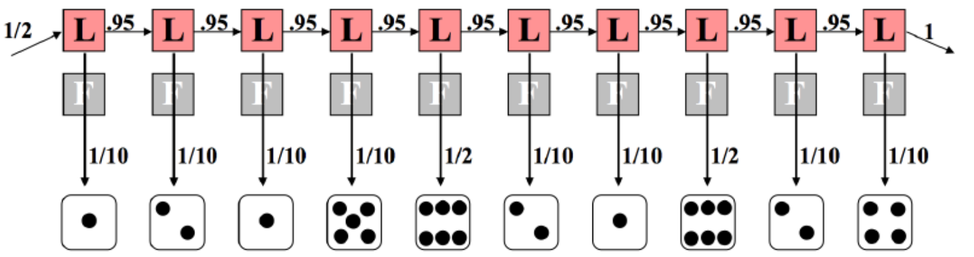

Tento výpočet je kľúčový pre porovnanie s predchádzajúcim výsledkom. Musíme si uvedomiť, že vo falošnej kocke (L) majú čísla **rôznu** pravdepodobnosť emisie, čo výpočet mierne komplikuje oproti férovej kocke.

Pripomeňme si pravdepodobnosti emisií pre stav L:

- Ak padne číslo 1, 2, 3, 4 alebo 5 : $P(x|L)=1/10$ (10%)
- Ak padne číslo 6 : $P(x|L)=1/2$ (50%)

Prípad 1: 2 hody kockou (Séria: 1, 2 | Kocky: L, L)

1. **Štart ($t=1$):** Začíname v stave „Falošná kocka“. Pravdepodobnosť je $1/2$.
2. **Prvá emisia ($t=1$):** Padlo číslo **1**. Keďže v stave L má číslo 1 šancu $1/10$, násobíme $1/10$.
3. **Prechod ($t=1\rightarrow 2$):** Zostávame v stave L. Pravdepodobnosť $P(L|L)=0,95$.
4. **Druhá emisia ($t=2$):** Padlo číslo **2**. Opäť, v stave L je šanca na číslo 2 presne $1/10$.

Výpočet pre 2 hody:

$$P(x,\pi)=\frac{1}{2}\times\frac{1}{10}\times 0,95\times\frac{1}{10}=\frac{1}{2}\times\left(\frac{1}{10}\right)^2\times(0,95)^1$$

2. Aplikácie HMM: Od kasína k biológii

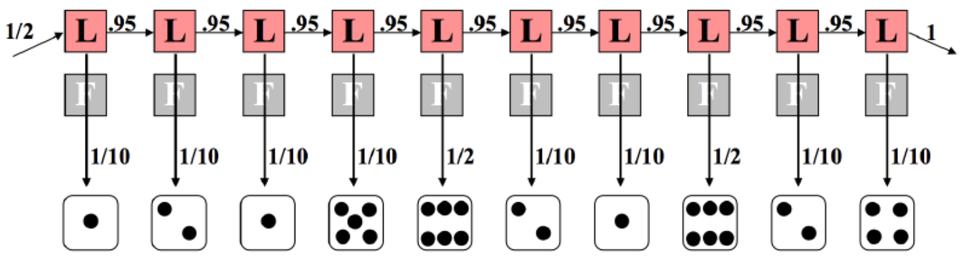

Prípad 2: 3 hody kockou (Séria: 1, 2, 6 | Kocky: L, L, L)

Tu prichádza zmena, pretože tretí hod je **šestka**.

1. Základ z prvých dvoch hodov zostáva.
1. **Prechod ($t = 2 \rightarrow 3$):** Zostávame v stave L. Šanca je 0,95.
2. **Tretia emisia ($t = 3$):** Padlo číslo **6**. Pozor! Vo falošnej kocke má šestka šancu $1/2$.

Výpočet pre 3 hody:

$$P(x,\pi) = \underbrace{\frac{1}{2}}_{\text{štart}} \times \underbrace{\frac{1}{10} \times \frac{1}{10} \times \frac{\mathbf{1}}{\mathbf{2}}}_{\text{emisie L}} \times \underbrace{0{,}95 \times 0{,}95}_{\text{prechody}}$$

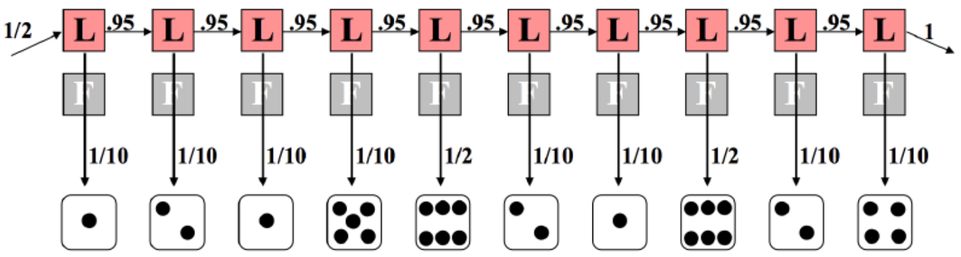

Prípad 3: Všetkých 10 hodov (podľa obrázka)

Pozorovaná sekvencia $x = \{1,2,1,5,6,2,1,6,2,4\}$ obsahuje:

1. 8-krát „nešestky“ (1, 2, 1, 5, 2, 1, 2, 4)

Pri ceste $\pi = \{L,L,L,L,L,L,L,L,L,L\}$ (vždy falošná) počítame takto:

1. **Štart:** $1/2$
2. **Emisie nešestiek:** Máme ich 8, každá má šancu $1/10 \Rightarrow (1/10)^8$
3. **Emisie šestiek:** Máme ich 2, každá má šancu $1/2 \Rightarrow (1/2)^2$
4. **Prechody:** Máme 9 prechodov v rámci stavu L $\Rightarrow (0,95)^9$

Celkový vzorec z učebnice:

$$P(x,\pi) = \frac{1}{2} \times \left(\frac{1}{10}\right)^8 \times \left(\frac{1}{2}\right)^2 \times (0,95)^9$$

Po dosadení čísel:

$$P(x,\pi) = 0,5 \times 0,00000001 \times 0,25 \times 0,63 \approx 7,9 \times 10^{-10}$$

2. Aplikácie HMM: Od kasína k biológii

Sumárne teda zvážme opačný extrém, kde krupiér vždy používa falošnú kocku, ako je znázornené na obrázku.

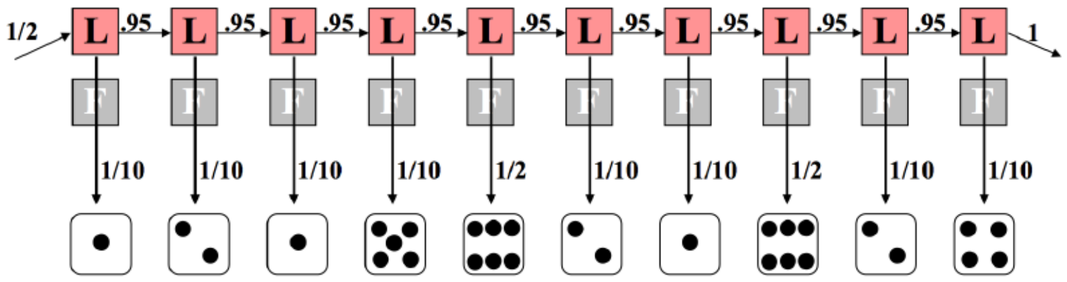

Výpočet je tu podobný, okrem rozdielu v člene emisnej pravdepodobnosti. Tentoraz 8 z 10 hodov nesie pravdepodobnosť $1/10$, pretože falošná kocka uprednostňuje šestky. Dva hody šestky majú každý pravdepodobnosť výskytu $1/2$. Opäť vynásobíme všetky tieto pravdepodobnosti podľa princípov nezávislosti a podmieňovania takto:

$$P(x,\pi) = \frac{1}{2} \times (1/10)^8 \times (1/2)^2 \times (0,95)^9 = 7,9 \times 10^{-10}$$

Všimnite si rozdiel v exponentoch: situácia, v ktorej sa používa iba férová kocka, má hodnotu 52×10^{-10} v porovnaní so $7,9 \times 10^{-10}$ pre falošnú kocku.

Preto je šesťkrát pravdepodobnejšie, že bola použitá iba férová kocka, než že bola použitá iba falošná. To nie je príliš prekvapujúce – dva hody zo desiatich, ktoré dali 6, nie sú veľmi ďaleko od očakávaného počtu 1,7 pre férovú kocku, ale sú oveľa ďalej od očakávaného počtu 5 pre falošnú kocku.

Porovnanie (Prečo to robíme?)

Teraz máme dve čísla pre tú istú sekvenciu x:

- **Pravdepodobnosť cesty "Vždy Férový":** 52×10^{-10}
- **Pravdepodobnosť cesty "Vždy Falošný":** $7,9 \times 10^{-10}$

Logický záver:

Sekvencia, ktorú sme videli, je **6,5-krát pravdepodobnejšia** pri férovej kocke. Prečo? Pretože falošná kocka „očakáva“ oveľa viac šestiek (v priemere 5 z 10). Keďže padli len dve, model falošnej kocky je „sklamaný“ a jeho celková pravdepodobnosť klesá.

2. Aplikácie HMM: Od kasína k biológii

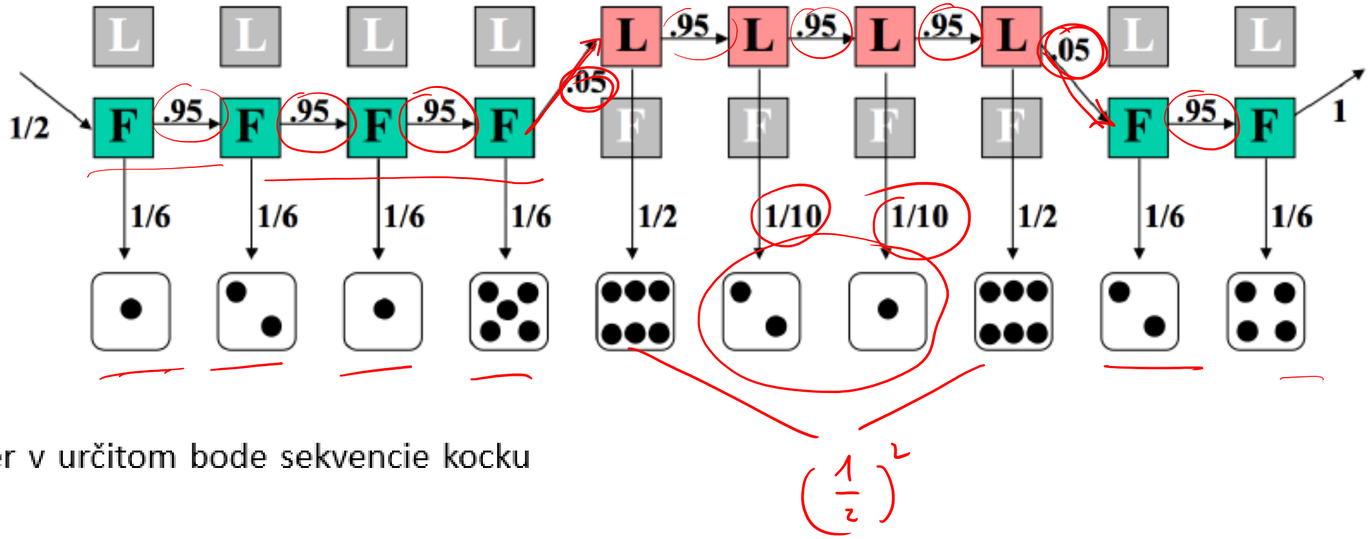

$\left(\frac{1}{2}\right)^2$

Pridanie komplexnosti

Teraz si predstavte zložitejší a zaujímavejší prípad, kde krupiér v určitom bode sekvencie kocku vymení.

Obrázok predstavuje odhad základného modelu. Opäť môžeme vypočítať vierohodnosť združenej pravdepodobnosti tejto sekvencie stavov a pozorovaní. Tu je šesť hodov vypočítaných s férovou kockou a štyri s falošnou. Okrem toho už nie všetky pravdepodobnosti prechodu sú 95 %; dve výmeny kocky majú každá pravdepodobnosť 5 %.

$$P(x,\pi) = \frac{1}{2} \times (1/10)^2 \times (1/2)^2 \times (1/6)^6 \times (0,95)^7 \times (0,05)^2 = 4,67 \times 10^{-11}$$

Je jasné, že náš odhad je oveľa menej pravdepodobný než ktorýkoľvek z predchádzajúcich dvoch prípadov. Nemôžeme však týmto spôsobom vypočítať všetky možné scenáre, aby sme našli ten najpravdepodobnejší, takže potrebujeme nové techniky na odvodenie základného modelu. V uvedených prípadoch sme model viac-menej len hádali, ale to, čo chceme, je spôsob, ako systematicky odvodzovať pravdepodobné modely. To sa musí vykonať pomocou dekódovacích algoritmov HMM, ktoré budú popísané neskôr.

2. Aplikácie HMM: Od kasína k biológii

Poďme si teda rozobrať ten najzaujímavejší prípad – situáciu, kedy dôjde k **prepnutiu (switchu)** medzi kockami. Toto je kľúč k pochopeniu toho, ako HMM dokáže identifikovať hranice medzi biologickými regiónmi (napríklad kde končí exón a začína intrón).

Predstavme si opäť sekvenciu 10 hodov, ale tentoraz predpokladáme, že krupiér po 6. hode vymenil férovú kocku za falošnú.

Sekvencia hodov (x): 1, 2, 1, 5, 6, 2 (prvých 6) + 1, 6, 2, 4 (zvyšné 4)

Predpokladaná cesta (π): F, F, F, F, F, F (6x Férová) $\rightarrow$ L, L, L, L (4x Falošná)

Aby sme vypočítali celkovú pravdepodobnosť $P(x,\pi)$, musíme túto „cestu“ rozdeliť na logické bloky.

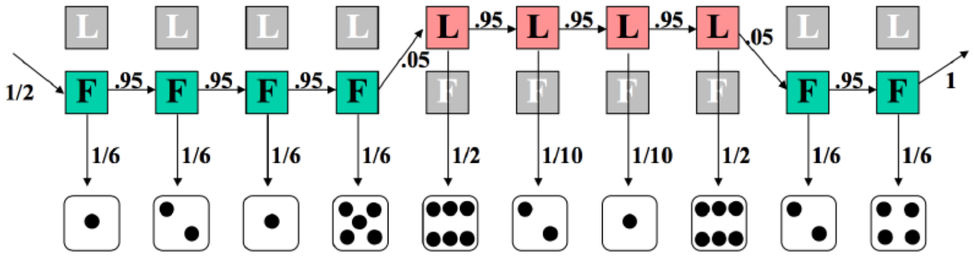

---

1. Blok: Štart a prvých 6 hodov (Férová kocka)

Tento blok už poznáme. Počítame šancu, že začneme s férovou kockou a zostaneme pri nej 5-krát za sebou.

- **Štart:** $1/2$
- **Emisie (6 hodov):** $(1/6)^6$
- **Prechody (5 krokov):** $(0,95)^5$ – *Pozor, tu je len 5 prechodov, lebo šiesty prechod nás už vedie do iného stavu!*

2. Blok: Bod zlomu (Prechod $F \to L$)

Tu sa deje tá „mágia“. Musíme započítať pravdepodobnosť, že krupiér urobil vedomé rozhodnutie vymeniť kocku.

- **Pravdepodobnosť prepnutia:** 0,05 (podľa modelu je 5 % šanca, že po férovej kocke nasleduje falošná).

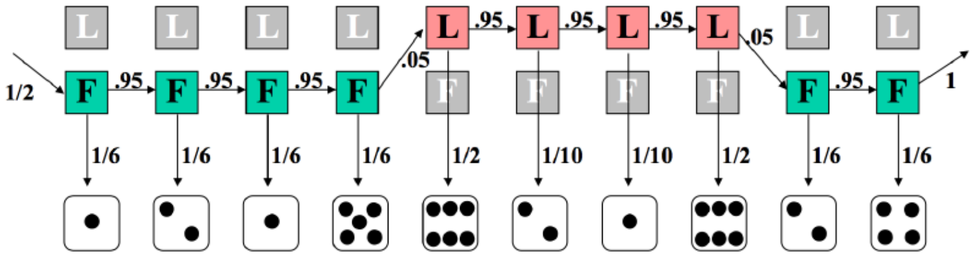

---

3. Blok: Posledné 4 hody (Falošná kocka)

Teraz sme v stave „Loaded“ (L). Musíme započítať emisie pre túto konkrétnu kocku a prechody v rámci tohto nového stavu.

- **Emisie (4 hody):**
  - Pre čísla 1, 2, 4 je šanca $1/10$. (Máme tri takéto hody: 1, 2, 4). $\to (1/10)^3$
  - Pre číslo 6 je šanca $1/2$. (Máme jeden takýto hod: 6). $\to (1/2)^1$
- **Prechody v stave L (3 kroky):** Zostávame pri falošnej kocke 3-krát za sebou. $\to (0,95)^3$

Celkový vzorec pre cestu s výmenou:

Keď to všetko spojíme (vynásobíme), dostaneme presne to, čo sme napísali

$$P(x,\pi) = \underbrace{\frac{1}{2}}_{\text{štart}} \times \underbrace{\left(\frac{1}{6}\right)^6}_{\text{Emisie F}} \times \underbrace{(0,95)^5}_{\text{Zotrvanie v F}} \times \underbrace{\mathbf{0,05}}_{\text{PRECHOD } F \to L} \times \underbrace{\left(\frac{1}{10}\right)^3 \times \left(\frac{1}{2}\right)^1}_{\text{Emisie L}} \times \underbrace{(0,95)^3}_{\text{Zotrvanie v L}}$$

Po vypočítaní vyjde hodnota približne $4,67 \times 10^{-11}$.

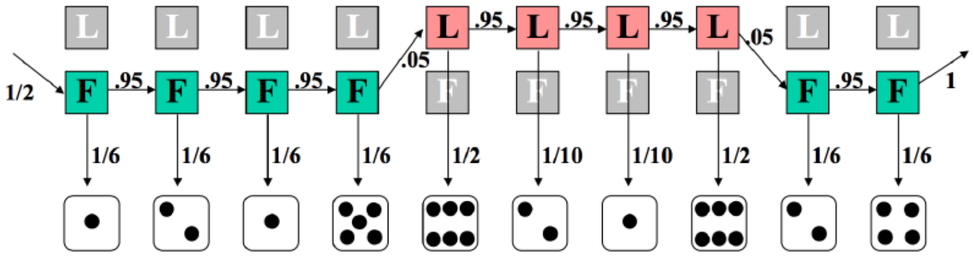

Prečo je toto číslo také dôležité pre vašu prácu?

Všimnite si dramatický rozdiel:

1. **Vždy férová cesta:** $52,0 \times 10^{-10}$
2. **Cesta s výmenou:** $0,467 \times 10^{-10}$ (po úprave exponentu)

Záver: Naša „uhádnutá“ cesta s výmenou je asi **111-krát menej pravdepodobná** než cesta, kde by bol krupiér stále poctivý.

Prečo je to tak?

Pretože v našej sekcii hodov pre falošnú kocku (1, 6, 2, 4) padla **iba jedna šestka**. Falošná kocka je však „stavaná“ na to, aby ich hádzala veľa. Matematika nám hovorí: *„Nedáva zmysel, aby krupiér riskoval odhalenie pri výmene kocky na falošnú (5% šanca), ak potom aj tak hodí len jednu šestku.“*

2. Aplikácie HMM: Od kasína k biológii

Príklad o **nepoctivom kasíne** je základným pilierom pre pochopenie HMM, pretože jasne oddeľuje to, čo vidíme, od toho, čo sa v skutočnosti deje. Poďme si ho rozobrať do hĺbky z hľadiska mechaniky, štatistiky a logiky rozhodovania.

---

1. Architektúra modelu: Dve vrstvy reality

V tomto modeli musíme rozlišovať medzi **stavom** a **emisiou**:

- **Skrytá vrstva (Hidden States):** Krupiér má v ruke buď férovú kocku (F), alebo falošnú (L). To je „stav“ systému. Vy ako hráč neviete, ktorú kocku práve drží.
- **Pozorovateľná vrstva (Emissions):** To, čo dopadne na stôl – čísla $\{1,2,3,4,5,6\}$. To sú „emisie“.

Pravdepodobnosti emisií (Prečo je falošná kocka záludná?):

- Pri férovej kocke je šanca na každé číslo rovnaká: $16,6\%$.
- Pri falošnej kocke je šanca na čísla $1-5$ len 10%, ale šanca na **šestku je až** 50%.
- *Logika:* Falošná kocka nie je nastavená tak, aby hádzala *iba* šestky (to by ste si hneď všimli), ale aby ich hádzala *štatisticky častejšie*.

2. Dynamika systému: Pravdepodobnosti prechodu (A)

Krupiér nemení kocku náhodne po každom hode. Existuje tu určitá „zotrvačnosť“.

- Pravdepodobnosť zotrvania (0,95): Ak krupiér práve používa férovú kocku, s 95% pravdepodobnosťou ju použije aj v ďalšom kole. To isté platí pre falošnú.
- Pravdepodobnosť zmeny (0,05): Existuje len 5% šanca, že krupiér kocku vymení.
- Interpretácia: To znamená, že kocky sa vyskytujú v „blokoch“. Ak krupiér prepne na falošnú kocku, pravdepodobne s ňou bude hádzať dlhší čas (v priemere 20 hodov), kým ju opäť vymení.

---

3. Problém pravdepodobnosti: Prečo sú čísla také malé?

V texte sme videli výsledky ako $5,2\times10^{-9}$. Prečo?

Predstavte si, že hodíte kockou 10-krát. Počet všetkých možných výsledkov je 6^{10}, čo je 60466176 **kombinácií**.

Keď počítame pravdepodobnosť jednej konkrétnej sekvencie (napr. 1, 2, 1, 5, 6, 2, 1, 6, 2, 4), počítame vlastne šancu, že zo všetkých tých miliónov možností nastane práve táto jedna. Preto sú tie čísla také malé.

Kľúč k pochopeniu: V HMM nás nezaujíma absolútna hodnota (napr. $0,0000000052$), ale **relatívne porovnanie**.

- Pýtame sa: „Je táto sekvencia pravdepodobnejšia pri scenári, že krupiér bol poctivý, alebo pri scenári, že podvádzal?“

4. Logika rozhodovania (Vierohodnosť)

Uvažujme o dvoch extrémoch na sekvencii 10 hodov, kde padli **dve šestky**:

1. **Scenár „Vždy férový“:** Pri férovej kocke očakávame v priemere 1,67 šestky na 10 hodov. Dve šestky sú teda úplne normálny výsledok.
2. **Scenár „Vždy falošný“:** Pri falošnej kocke očakávame v priemere 5 šestiek na 10 hodov. Dve šestky sú pre tento stav „sklamaním“.

Výsledok porovnania: Preto nám matematika v učebnici ukázala, že scenár „Vždy férový“ je **6-krát pravdepodobnejší**. Ak by však v tých 10 hodoch padlo osem šestiek, pomer by sa dramaticky otočil v prospech falošnej kocky.

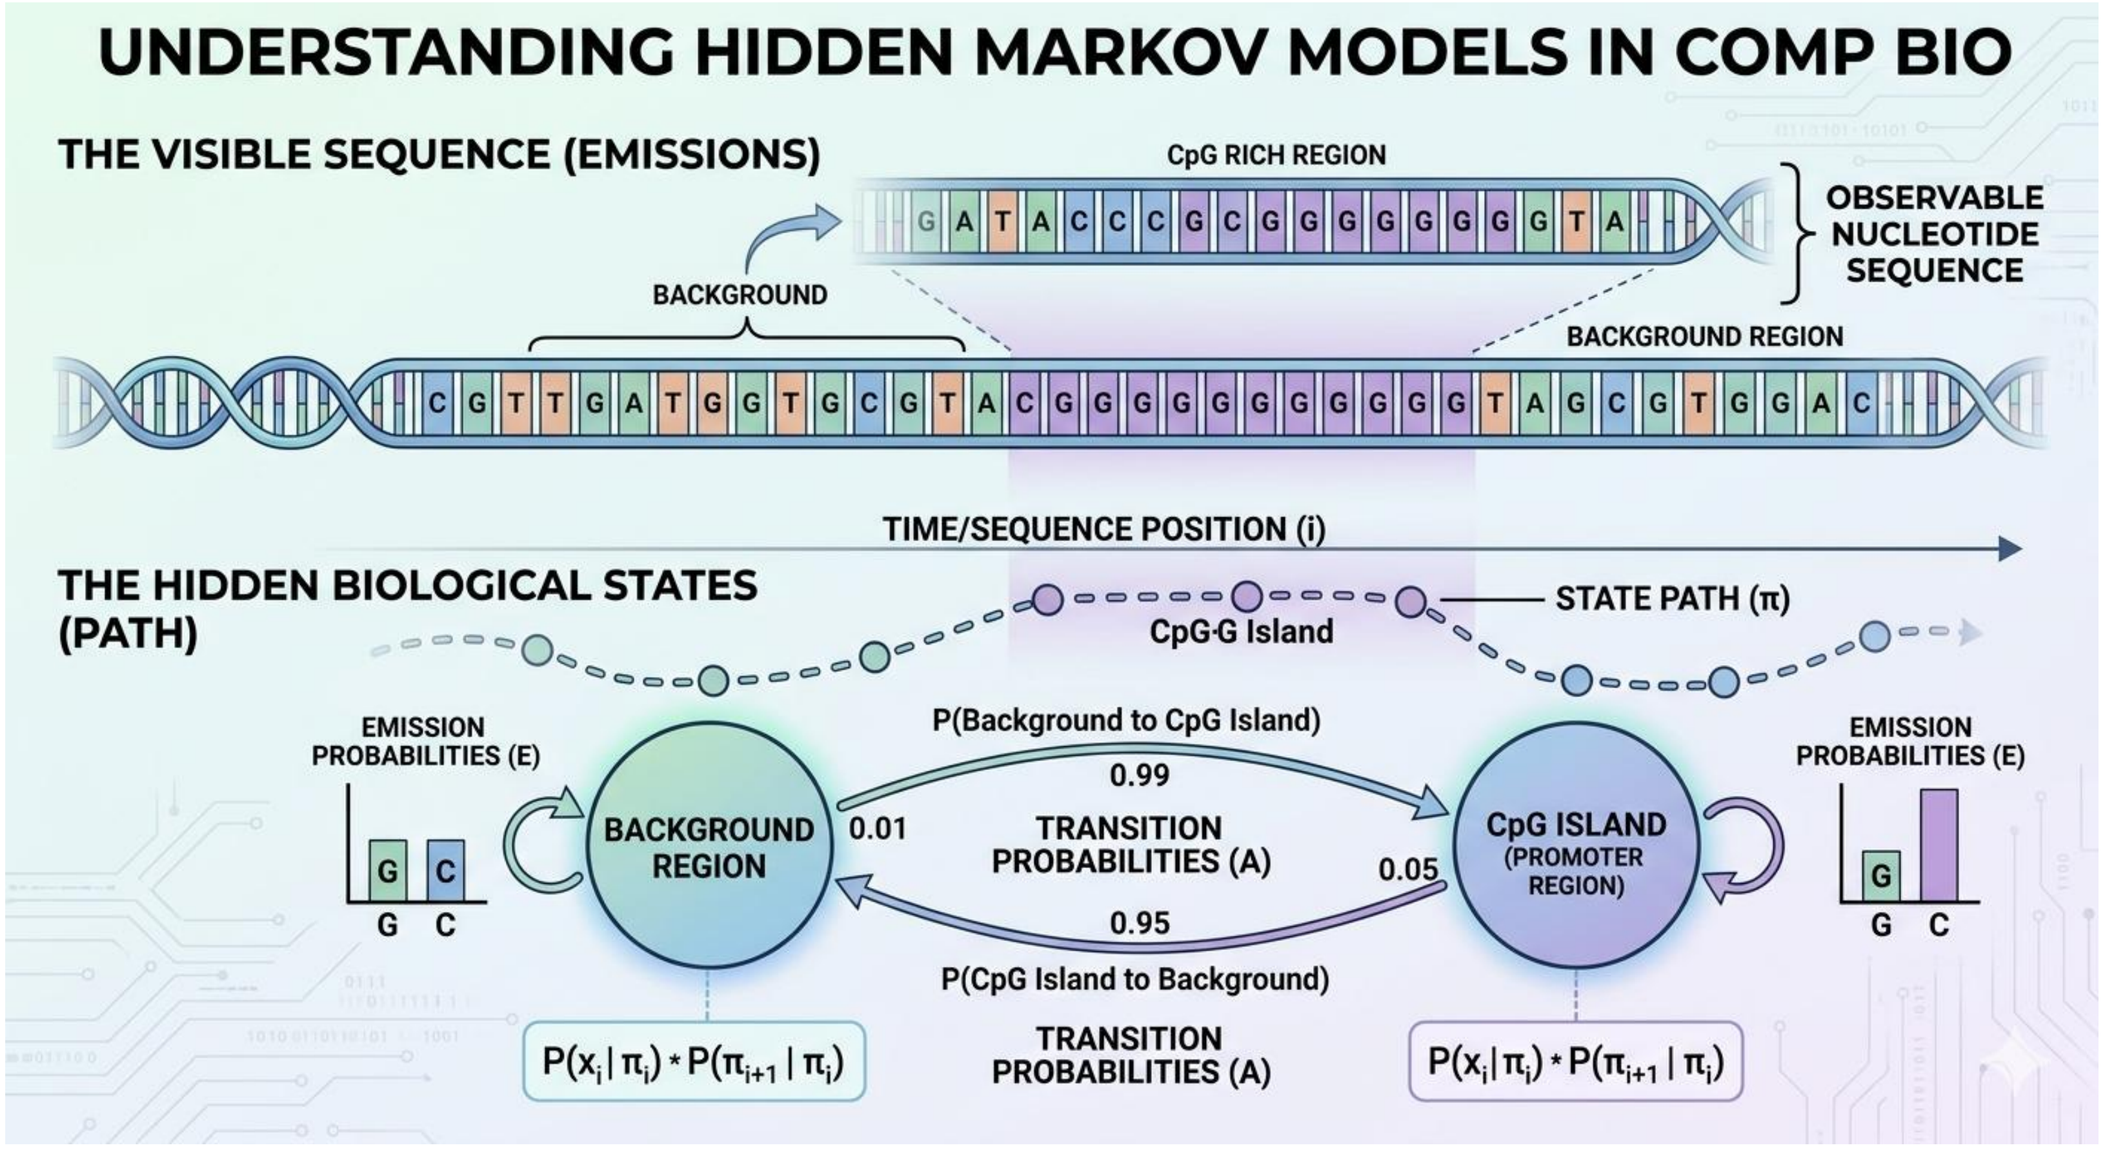
UNDERSTANDING HIDDEN MARKOV MODELS IN COMP BIO
THE VISIBLE SEQUENCE (EMISSIONS)
CpG RICH REGION
G A T A C C C G C G G G G G G G G T A
OBSERVABLE NUCLEOTIDE SEQUENCE
BACKGROUND
BACKGROUND REGION
C G T T G A T G G T G C G T A C G G G G G G G G G G G T A G C G T G G A C
TIME/SEQUENCE POSITION (i)
THE HIDDEN BIOLOGICAL STATES (PATH)
STATE PATH (π)
CpG-G Island
EMISSION PROBABILITIES (E)
G C
G C
BACKGROUND REGION
P(Background to CpG Island)
0.99
0.01
TRANSITION PROBABILITIES (A)
0.05
0.95
P(CpG Island to Background)
CpG ISLAND (PROMOTER REGION)
EMISSION PROBABILITIES (E)
G
G C
$P(x_i | \pi_i) * P(\pi_{i+1} | \pi_i)$
TRANSITION PROBABILITIES (A)
$P(x_i | \pi_i) * P(\pi_{i+1} | \pi_i)$

Späť k biológii

Teraz, keď sme HMM formalizovali, chceme ich použiť na riešenie niektorých skutočných biologických problémov.

HMM sú v skutočnosti skvelým nástrojom na analýzu génových sekvencií, pretože sa na sekvenciu DNA môžeme pozerať tak, akoby bola emitovaná zmesou modelov. Tie môžu zahŕňať intróny, exóny, transkripčné faktory atď.

Hoci môžeme mať nejaké vzorové dáta, ktoré priraďujú modely k sekvenciám DNA, v prípade, keď začíname s novou sekvenciou DNA, môžeme použiť HMM na prisúdenie potenciálnych modelov tejto sekvencii.

Najprv si predstavíme a rozoberieme jednoduchý príklad.

Potom preskúmame niektoré zaujímavé biologické aplikácie HMM a nakoniec opíšeme techniky HMM, ktoré sa dajú použiť na riešenie problémov vznikajúcich pri takejto prvotnej/natívnej analýze.

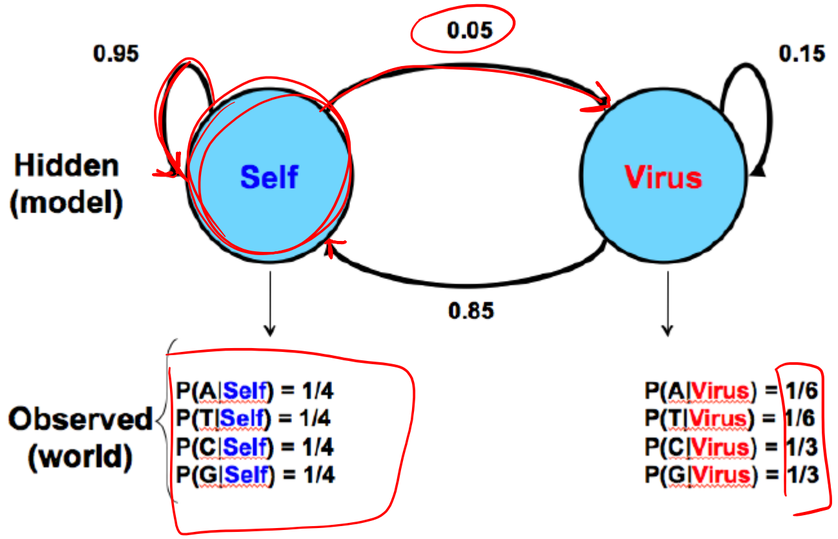

Jednoduchý príklad:

Hľadanie oblastí bohatých na GC

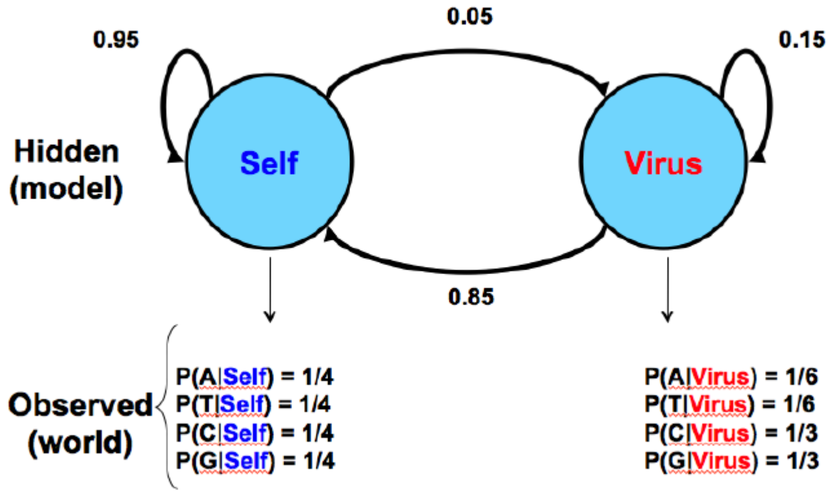

V tomto scenári chceme nájsť oblasti bohaté na GC modelovaním nukleotidových sekvencií čerpaných z dvoch rôznych distribúcií: pozadia (background) a promótora.

- Oblasti pozadia majú rovnomernú distribúciu A, T, G, C s pravdepodobnosťou 0,25 pre každú z nich.
- Oblasti promótora majú na druhej strane nerovnomerné pravdepodobnosti napr. (A: 0,15, T: 0,13, G: 0,30, C: 0,42). Počiatočné rozdelenie stavov sa môžeme naučiť na základe pravdepodobností ustáleného stavu.

Na základe pozorovania jediného nukleotidu nemôžeme o oblasti, z ktorej pochádza, povedať nič, pretože každá z nich emituje každý nukleotid s určitou pravdepodobnosťou.

Naším cieľom je však pozrieť sa na sekvenciu a identifikovať, ktoré oblasti pochádzajú z distribúcie pozadia (B) a ktoré oblasti sú z distribúcie promótora (P).

2. Aplikácie HMM: Od kasína k biológii

Tento model predpokladá, **že vírusové inzeráty (vložené sekvencie) budú mať vyššiu prevalenciu CpG, čo vedie k vyšším pravdepodobnostiam emisie C a G.**

Okrem toho sa a priori predpokladá, že je veľmi pravdepodobné, že sekvencia pochádza z jej vlastného genómu a že prechody na vírusovú DNA sú nepravdepodobné, čo vedie k pravdepodobnostiam prechodu zobrazeným v modeli. Ak vezmeme tento model ako hypotézu, pozorovali by sme frekvencie C a G, ktoré by nám poskytli indície o zdroji predmetnej sekvencie.

Podrobnejšie vysvetlenie:

Je to rovnaká logika, ktorú sme preberali pri **kroku 1: Modelovanie**. Hovorí o tom, ako nastavujeme naše očakávania (pravdepodobnosti) do HMM:

1. **Emisná logika (C a G):** Vírusy sa v genóme často prezradia tým, že majú „nahlustené“ dvojice C a G (tzv. CpG ostrovy). Preto v stave „Vírus“ nastavíme v modeli vyššiu šancu, že zo sekvencie „vypadne“ (emituje sa) písmeno C alebo G.
2. **A priori predpoklad:** To je odborný termín pre „to, čo si myslíme vopred“. Keďže vírusy nie sú v DNA na každom kroku, náš model nastavíme tak, aby preferoval stav „Vlastný genóm“.
3. **Logika prechodov:** Aby model nepreskakoval z vlastnej DNA na vírusovú pri každom jednom náhodnom výskyte písmena G, nastavíme pravdepodobnosť prechodu ($B \rightarrow P$) na veľmi nízku hodnotu. Model sa tak „prepne“ do stavu vírus len vtedy, ak uvidí skutočne silný a dlhý signál (veľa C a G po sebe).

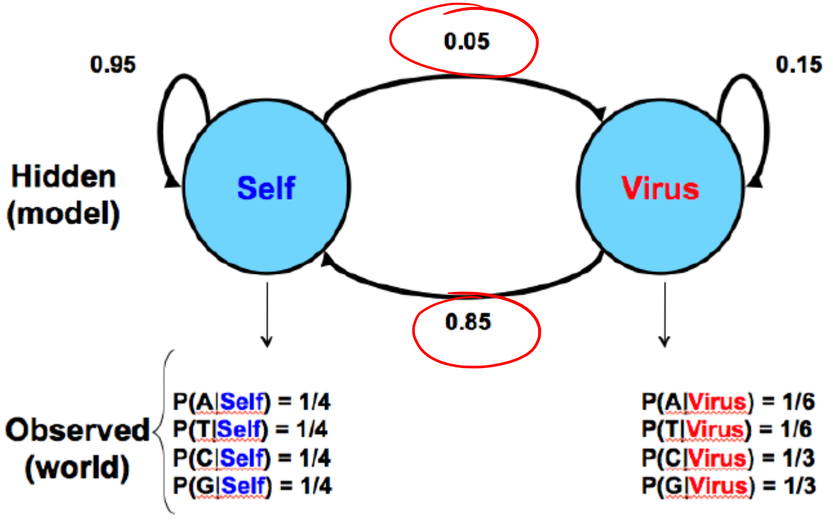

2. Aplikácie HMM: Od kasína k biológii

Pravdepodobnosti prechodu a emisie sú odvodené z príslušných distribúcií a priemernej dĺžky oblastí každého stavu, kde

- x = vektor pozorovateľných emisií pozostávajúci z $\{A,T,G,C\}$;
- π = vektor stavov v ceste (napr. BPPBP); a
- π^* = cesta s maximálnou vierohodnosťou. V našej interpretácii sa cesta s maximálnou vierohodnosťou nájde pomocou dynamického programovania – to bude neskôr.

HMM sú generatívne modely v tom zmysle, že HMM udáva pravdepodobnosť emisie pri danom stave, čím v podstate hovorí, nakoľko je pravdepodobné, že určité stavy vygenerujú danú sekvenciu. Preto môžeme začať kdekoľvek a vždy budeme schopní spustiť generatívny model pre prechody medzi stavmi.

V HMM si môžete vybrať počiatočný stav na základe vektora počiatočnej pravdepodobnosti. Vo vyššie uvedenom príklade začneme v stave B s vysokou pravdepodobnosťou, pretože väčšina miest nezodpovedá oblastiam promótora. Emisia sa potom vyžrebuje z distribúcie $P(X \mid B)$. Pravdepodobnostná distribúcia nasledujúceho stavu potom závisí len od skutočnosti, že sa nachádzame v stave pozadia, a je nezávislá od aktuálnej emisie, takže pravdepodobnosť zotrvania v stave B je 0,85 a pravdepodobnosť prechodu do stavu P je 0,15.

Pravdepodobnosť jednej takejto generácie môžeme vypočítať vynásobením pravdepodobností, že model urobí presne tie voľby, ktoré sme predpokladali.

Urobíme podobné príklady ako v prípade kasína, s rovnakou logikou, ktoré sú analogické s príkladmi s kockami uvedenými predtým. Najpravdepodobnejšou možnosťou z týchto troch bola tá, v ktorej boli všetky emisie vyžrebované z distribúcie pozadia. **Ale ako nájdeme tú najpravdepodobnejšiu zo všetkých možných ciest stavov?** Prístup hrubou silou spočíva vo výpočte pravdepodobnosti všetkých možností ako vyššie. Existuje však exponenciálny počet možných ciest, takže toto riešenie je výpočtovo nerealizovateľné. V nasledujúcich častiach vyvinieme algoritmy na riešenie tohto problému.

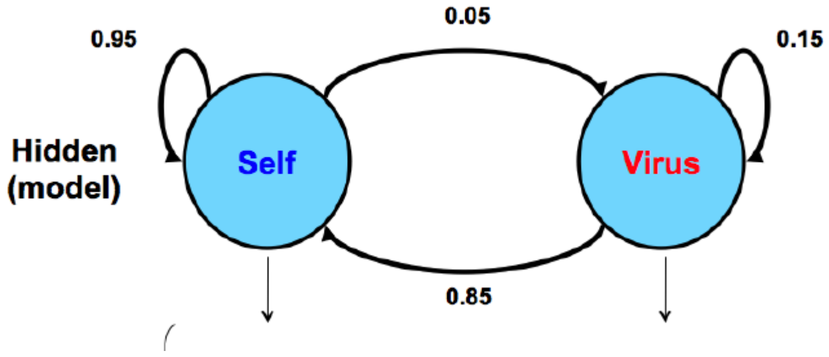

Modelujeme dva skryté stavy s odlišnými emisnými pravdepodobnosťami:
Jeden nukleotid (napr. „G“) nám nič nepovie – vyskytuje sa v oboch stavoch. Musíme sledovať **celú sekvenciu** (kontext), aby sme videli, či frekvencia G a C zodpovedá modelu promótora.

Nukleotid	Stav B (Pozadie)	Stav P (Promótor)
A	0,25 (25 %)	0,15 (15 %)
T	0,25 (25 %)	0,13 (13 %)
G	0,25 (25 %)	0,30 (30 %)
C	0,25 (25 %)	0,42 (42 %)

2. Aplikácie HMM: Od kasína k biológii

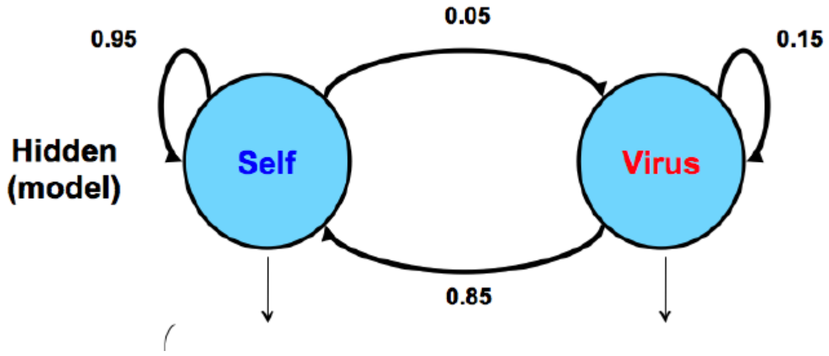

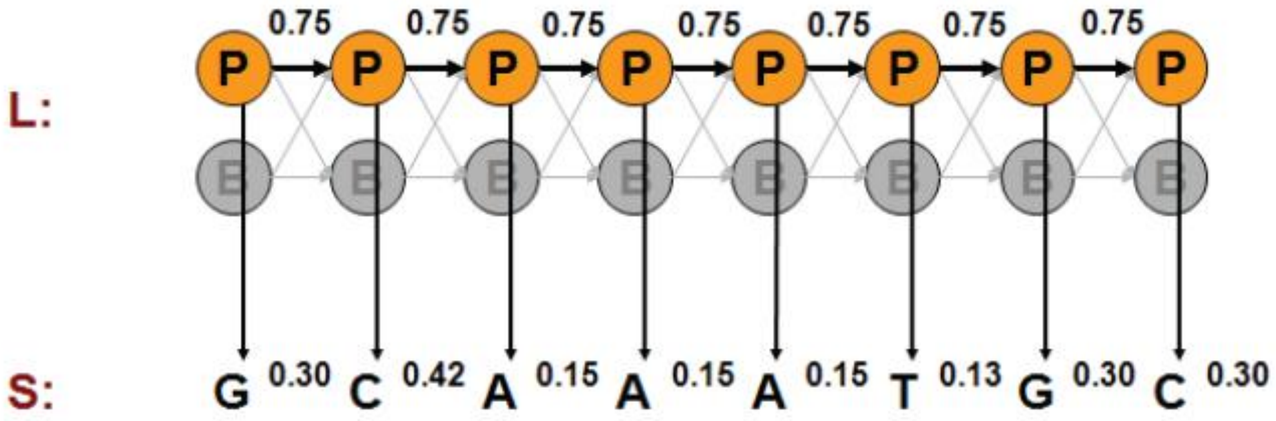

$$P(x, \pi_P) = a_P \times e_P(G) \times a_{PP} \times e_P(G) \times \cdots$$
$$= a_P \times (0.75)^7 \times (0.15)^3 \times (0.13) \times (0.3)^2 \times (0.42)^2$$
$$= 9.3 \times 10^{-7}$$

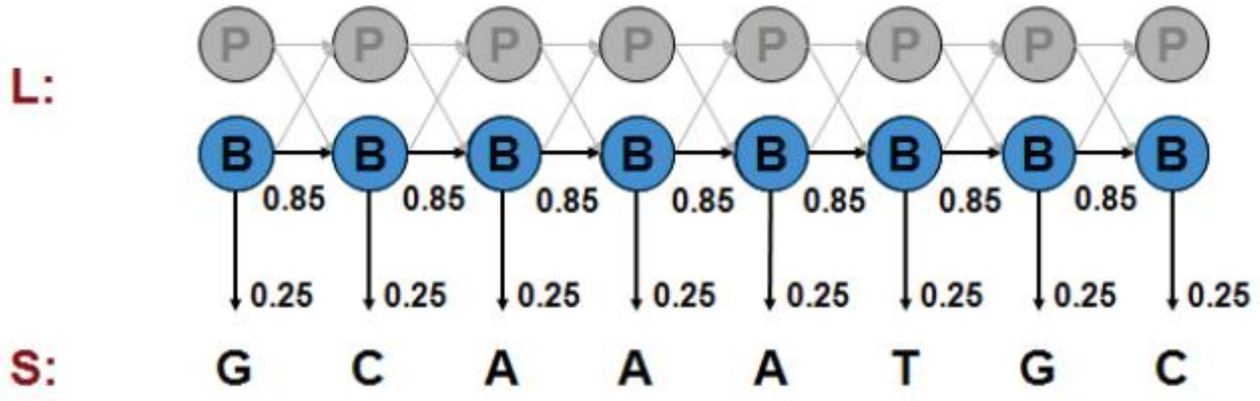

$$P(x, \pi_B) = (0.85)^7 \times (0.25)^8$$
$$= 4.9 \times 10^{-6}$$

Nukleotid	Stav B (Pozadie)	Stav P (Promótor)
A	0,25 (25 %)	0,15 (15 %)
T	0,25 (25 %)	0,13 (13 %)
G	0,25 (25 %)	0,30 (30 %)
C	0,25 (25 %)	0,42 (42 %)

2. Aplikácie HMM: Od kasína k biológii

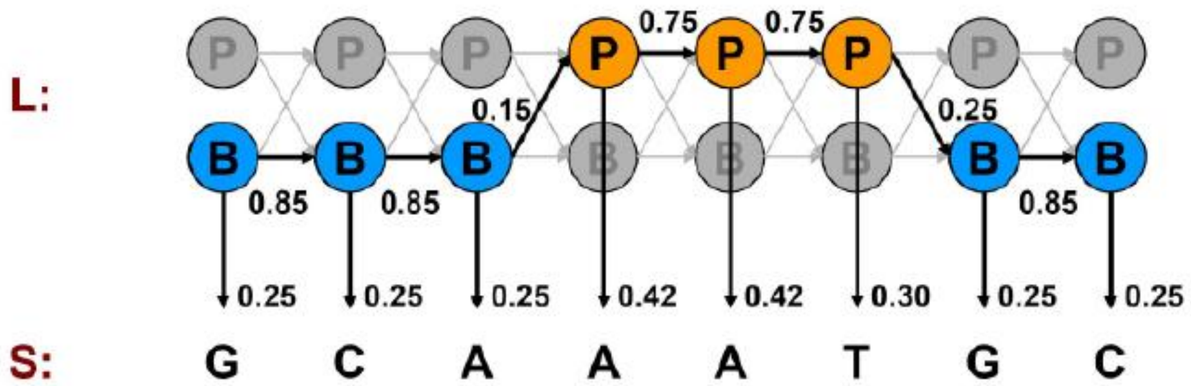

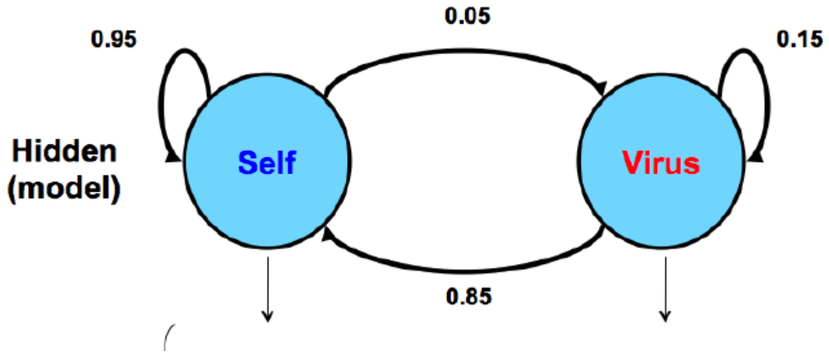

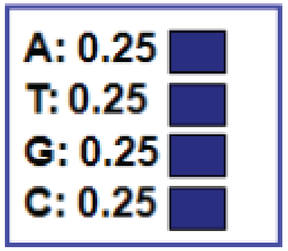

$$P = P(G \mid B)P(B_1 \mid B_0)P(C \mid B)P(B_2 \mid B_1)P(A \mid B)P(P_3 \mid B_2)\ldots P(C \mid B_7)$$

$$= (0.85)^3 \times (0.25)^6 \times (0.75)^2 \times (0.42)^2 \times 0.30 \times 0.15$$

$$= 6.7 \times 10^{-7}$$

Nukleotid	Stav B (Pozadie)	Stav P (Promótor)
A	0,25 (25 %)	0,15 (15 %)
T	0,25 (25 %)	0,13 (13 %)
G	0,25 (25 %)	0,30 (30 %)
C	0,25 (25 %)	0,42 (42 %)

Zhrnutie – HMM ako most medzi sekvenciou a funkciou

1. Analógia: Od kociek ku genómu

- **Emisie (To, čo vidíme):** Čísla na kocke (1-6) $\leftrightarrow$ Nukleotidy v DNA (A, C, G, T).
- **Skryté stavy (To, čo hľadáme):** Typ kocky (Férová/Falošná) $\leftrightarrow$ Biologická identita (Pozadie/Promótor/Vírus).

2. Tri piliere rozhodovania modelu

Model sa nerozhoduje náhodne, ale váži tri typy informácií:

1. **Emisná pravdepodobnosť (E):** Aká je šanca, že v tomto stave uvidím práve tento nukleotid? (napr. „C“ je v promótore bežnejšie než v pozadí).
2. **Pravdepodobnosť prechodu (A):** Aká je šanca, že tu začína nový región? (zohľadňuje priemernú dĺžku génov/promótorov).
3. **A priori očakávanie (p):** Čo vieme vopred? (napr. že väčšina genómu nie je vírusová).

3. Hlavná výzva: Problém dekódovania

- Pri sekvencii DNA s dĺžkou L existuje astronomické množstvo možných ciest (anotácií).
- **Cieľ:** Nájsť cestu $\boxed{\pi^*}$, ktorá maximalizuje združenú pravdepodobnosť $P(x, \pi)$.
- **Riešenie:** Prechod od manuálneho násobenia k **dynamickému programovaniu** (Viterbiho a Forward algoritmus).

Kľúčové ponaučenie: HMM nám umožňuje interpretovať „šum“ v sekvencii nie ako náhodu, ale ako signál skrytých biologických procesov.